

Aprendizado de Máquina

Aula 7: Algoritmos baseados em probabilidade (parte 2)

André C. P. L. F de Carvalho
ICMC/USP

andre@icmc.usp.br



Tópicos a serem abordados nesta parte

- Aproximação de funções
- Tarefas de regressão
- Regressão linear simples

Introdução

- Regressão é uma das principais tarefas preditivas
- Objetivo:
 - Aprender (aproximar) uma função que associa:
 - A descrição de um objeto, vetor de valores, conjunto de variáveis independentes (atributos preditivos), a
 - Um valor real de uma variável dependente (atributo alvo) que rotula o objeto
 - Que pode ser utilizada para prever, com boa capacidade preditiva, o rótulo de um novo objeto


Aproximação de funções

- Procura uma função hipótese que se ajuste aos dados disponíveis
 - Permite prever o valor de saída para um novo objeto
 - Representado por um vetor de valores de entrada
 - Supor que você estudou 9 horas para a prova



Aproximação de funções

- Procura uma função hipótese que se ajuste aos dados disponíveis
 - Permite prever o valor de saída para um novo objeto
 - Representado por um vetor de valores de entrada
 - Supor que você estudou 9 horas para a prova



Aproximação de funções

- Alternativa mais simples: aproximar por uma função linear


- Função linear:

- $f(x) = ax + b$
 - Coeficiente angular
 - Coeficiente linear

- Descobrir valor de a e de b

- Se você estudou 9 horas ($x=9$)

- Sua nota será 5,0 ($f(x)=5$)



- Função linear pode ser usada para prever valor da nota

- Tarefa de regressão

Aproximação de funções

- Alternativa mais simples: aproximar por uma função linear

- Função linear:

- $f(x) = ax + b$

Coeficiente angular
Coeficiente linear

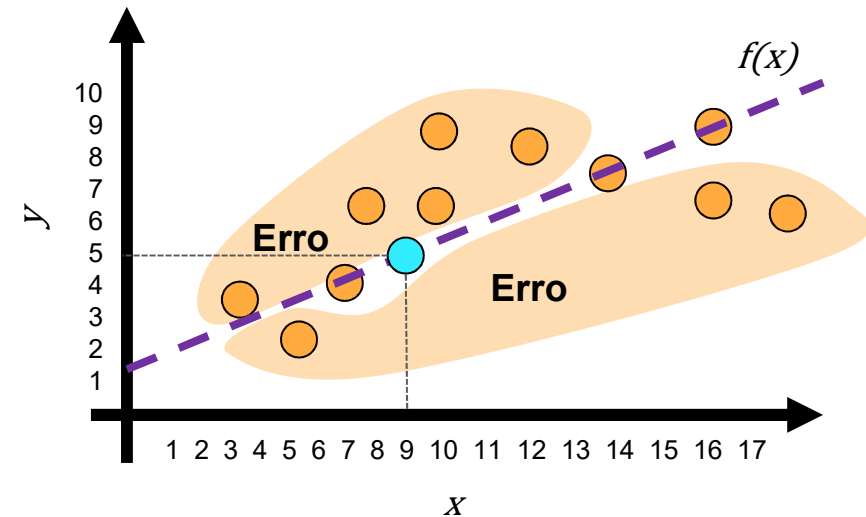
- Descobrir valor de a e de b

- Se você estudou 9 horas ($x=9$)

- Sua nota será 5,0 ($f(x)=5$)

- Função linear pode ser usada para prever valor da nota

- Tarefa de regressão



Tarefas de regressão

- Buscam função de regressão que melhor se aproxime aos dados
 - Minimizando o erro para todo o conjunto de dados
 - Algoritmo de **regressão linear** ajuda a encontrar esta função (hipótese, modelo)

$$h_{\beta}(x) = \beta_0 + \beta_1 x_1 + \varepsilon \quad (f(x) = ax + b)$$

onde:

β_j é o $j^{\text{ésimo}}$ parâmetro ($j = 1, \dots, d$)

β_0 é o termo de interceptação

x_1 é a variável independente

ε é o termo residual (ruído, erro de estimação da função verdadeira)

Tarefas de regressão

- Buscam função de regressão que melhor se aproxime aos dados
 - Minimizando o erro para todo o conjunto de dados
 - Algoritmo de **regressão linear** ajuda a encontrar esta função (hipótese, modelo)

$$h_{\beta}(x) = \beta_0 + \beta_1 x_1 \quad (f(x) = ax + b)$$

onde:

β_j é o $j^{\text{ésimo}}$ parâmetro ($j = 1, \dots, d$)

β_0 é o termo de interceptação

x_1 é a variável independente

Tarefas de regressão

- Buscam função de regressão que melhor se aproxime aos dados
 - Minimizando o erro para todo o conjunto de dados
 - Algoritmo de **regressão linear** ajuda a encontrar esta função (hipótese, modelo)

$$h_{\theta}(x) = \theta_0 + \theta_1 x_1 \quad (f(x) = ax + b)$$

onde:

θ_j é o $j^{\text{ésimo}}$ parâmetro ($j = 1, \dots, d$)

θ_0 é o termo de interceptação

x_1 é a variável independente

Tarefas de regressão

- Buscam função de regressão que melhor se aproxime aos dados
 - Minimizando o erro para todo o conjunto de dados
 - Algoritmo de **regressão linear** ajuda a encontrar esta função (hipótese, modelo)

$$h_w(x) = w_0 + w_1 x_1$$

onde:

w_j é o $j^{\text{ésimo}}$ parâmetro ($j = 1, \dots, d$)

w_0 é o termo de interceptação

x_1 é a variável independente

Tarefas de regressão

- Necessário encontrar valores dos parâmetros w_0 e w_1 que minimizem o erro da função hipótese $h_w(x) = w_0 + w_1x$
 - $h_w(x)$: função linear
 - w_0 : coeficiente linear da reta
 - w_1 : coeficiente angular da reta
- Erro cometido pela função hipótese pode ser estimado por uma função de custo $J(w_0, w_1) = \frac{1}{n} \sum_{i=1}^n (y^i - h_w(x^i))^2$

Tarefas de regressão

- Necessário encontrar valores dos parâmetros w_0 e w_1 que minimizem o erro da função hipótese $f(x) = w_0 + w_1x$
 - $f(x)$: função linear
 - w_0 : coeficiente linear da reta
 - w_1 : coeficiente angular da reta
- Erro cometido pela função hipótese pode ser estimado por uma função de custo $J(w_0, w_1) = \frac{1}{n} \sum_{i=1}^n (y^i - f(x^i))^2$

Aprendizado

- Buscam minimizar função de custo


- Achar valores de w (w_0 e w_1) que gerem a função $J(w)$ de menor custo (taxa de erro)
- Pode ser ilustrado por um gráfico que mostra a relação entre valores de parâmetros e valor do erro
- Buscar w que minimiza $(y-f(x))^2$

$$\min_{w_0 w_1} (y - f(x))^2$$

$$\min_{w_0 w_1} \sum_{i=1}^n (y^i - f(x^i))^2 \quad \text{Erro total}$$

$$\min_{w_0 w_1} \frac{1}{n} \sum_{i=1}^n (y^i - f(x^i))^2 \quad \text{Erro médio}$$


$$\min_{w_0 w_1} J(w_0, w_1) \quad \text{Erro quadrático médio (MSE)}$$



Aproximação da função hipótese

- Minimizar erro quadrático médio (MSE, Mean Squared Error)
 - Média da área dos quadrados entre saída real (y^i) e saída estimada ($f(x^i)$)


$$MSE = \frac{1}{n} \sum_{i=1}^n (y^i - f(x^i))^2$$



Trabalhamos com duas funções


- Função hipótese:

- $f(x) = 2 + w_1 x_1$ (seja w_0 fixo, = 2)
- $f(x) = 2 + 0,9x$



- Função de custo:


- $J(w_1) = \frac{1}{n} \sum_{i=1}^n (y^i - f(x^i))^2$
- $J(0,9) = 0 + 0 + 0 + 0 = 0$



Trabalhamos com duas funções


- Função hipótese:

- $f(x) = 2 + w_1 x_1$ (seja w_0 fixo, $= 2$)
- $f(x) = 2 + 0,9x$




- Função de custo:

- $J(w_1) = \frac{1}{n} \sum_{i=1}^n (y^i - f(x^i))^2$
- $J(0,9) = 1^2 + 1^2 + 1^2 + 1^2 / 4 = 1$




Avaliando diferentes valores de w_1

- Função hipótese:
 - $f(x) = 2 + w_1 x_1$ (seja w_0 fixo, = 2)
 - Diversos valores de w_1 (várias funções)




- Função de custo:
 - Calculada para cada valor de w_1
 - $J(w_1) = \frac{1}{n} \sum_{i=1}^n (y^i - f(x^i))^2$




Avaliando diferentes valores de w_1


- Função hipótese:
 - $f(x) = 2 + w_1 x_1$ (seja w_0 fixo, = 2)
 - Diversos valores de w_1 (várias funções)




- Função de custo:
 - Calculada para cada valor de w_1
 - $J(w_1) = \frac{1}{n} \sum_{i=1}^n (y^i - f(x^i))^2$




Ajuste de parâmetros




Ajuste de parâmetros




Ajuste de parâmetros




Ajuste de parâmetros



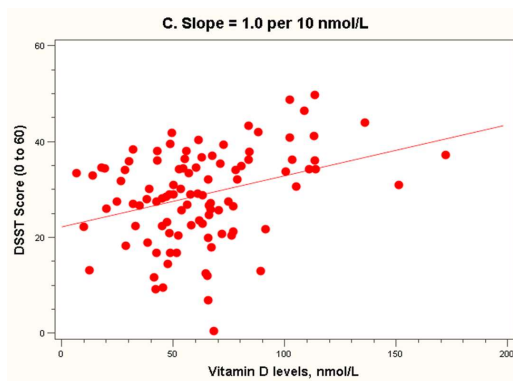
Ajuste de parâmetros



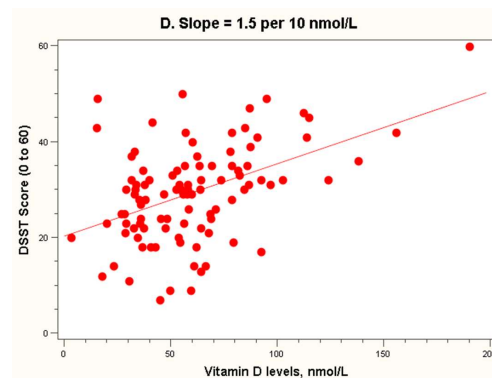
$$f(x) = 28$$



$$f(x) = 26 + 0,5x$$



$$f(x) = 22 + x$$



$$f(x) = 20 + 1,5x$$

Sumarizando

- Regressão linear simples
- Função hipótese: $h_w(x) = w_0 + w_1x$ ou $f(x) = w_0 + w_1x$
- Parâmetros: w_0, w_1
- Função custo: $J(w_0, w_1) = \frac{1}{n} \sum_{i=1}^n (y^i - f(x^i))^2$
 - Para simplificar cálculos, pode ser usada a função $J(w_0, w_1) = \frac{1}{2n} \sum_{i=1}^n (y^i - f(x^i))^2$
- Objetivo: $\min_{w_0, w_1} J(w_0, w_1)$

Continua no próximo
vídeo e conjunto de
slídes