

Aprendizado de Máquina

Aula 7: Algoritmos baseados em probabilidade (parte 4)

André C. P. L. F de Carvalho
ICMC/USP

andre@icmc.usp.br



Tópicos

- Introdução
- Modelos preditivos
- Tarefas de regressão
- Aproximação de funções
- Regressão linear simples
- Regressão polinomial
- Algoritmo de ajuste de parâmetros
- Regressão linear múltipla
- Regularização

Regressão múltipla

- De acordo com o número de variáveis independentes consideradas, uma tarefa de regressão pode ser
 - Simples: uma única variável independente (atributo preditivo)
 - $f(x) = w_0x_0 + w_1x_1$
 - Múltipla: mais de uma variável independente (atributo preditivo)
 - Linear
 - $f(x) = w_0x_0 + w_1x_1 + w_2x_2 + \dots + w_dx_d$
 - Polinomial
 - $f(x) = w_0x_0 + w_1x_1^3 - w_2x_1^2 + w_3x_2^4 + w_4x_1^7$

Dados estruturados para tarefa de regressão

Atributos de entrada (preditivos)

Estudou	Assistiu	Jogou	Leu	Nota
20	6	5	2	7.0
10	2	4	1	3.0
30	8	0	3	10.0
10	7	1	2	8.0
6	6	3	1	6.0
4	0	0	0	1.0

Atributo alvo

Dados estruturados para tarefa de regressão

Atributos de entrada (preditivos)

Estudou	Assistiu	Jogou	Leu	Nota
20	6	5	2	7.0
10	2	4	1	3.0
30	8	0	3	10.0
10	7	1	2	8.0
6	6	3	1	6.0
4	0	0	0	1.0

Obs.:
 $x_2 = 8$
 x_0 é uma constante

Atributo alvo

Regressão múltipla

- Busca função capaz de associar
 - Valores de mais de um atributo preditivo ao
 - Valor de um atributo alvo

$$f(x) = w_0 + w_1x_1 + w_2x_2 + \dots + w_dx_d$$

onde:

w_j é o parâmetro j

x_j é o valor da variável x_j

d é o número de parâmetros

Regressão múltipla

- Busca função capaz de associar
 - Valores de mais de um atributo preditivo a
 - Valor de um atributo alvo

$$f(x) = w_0x_0 + w_1x_1 + w_2x_2 + \dots + w_dx_d$$

onde:

w_j é o parâmetro j

x_j é o valor da variável x_j

x_0 é o valor constante 1

$d + 1$ é o número de parâmetros

- Ex.: $f(x) = 3x_0 - 2x_1^2 + x_1^3 + 5x_2^5 + 2x_3$

Regressão múltipla

- Aplicação de um modelo de regressão linear pode ser visto como uma multiplicação de matrizes

$$\begin{aligned} f(x) &= w_0x_0 + w_1x_1 + w_2x_2 + \dots + w_dx_d \\ &= w^T \cdot x \end{aligned}$$

- Exemplo para $d = 4$: $w = \begin{bmatrix} 1 \\ 1 \\ -1 \\ 100 \\ 1 \end{bmatrix}$ e $x = \begin{bmatrix} 1 \\ 0 \\ 1 \\ 0 \\ 0 \end{bmatrix}$

Regressão múltipla

- Aplicação de um modelo de regressão linear pode ser visto como uma multiplicação de matrizes

$$\begin{aligned} f(x) &= w_0x_0 + w_1x_1 + w_2x_2 + \dots + w_dx_d \\ &= w^T \cdot x \end{aligned}$$

- Exemplo para $d = 4$: $w = \begin{bmatrix} 1 \\ 1 \\ -1 \\ 100 \\ 1 \end{bmatrix}$ e $x = \begin{bmatrix} 1 \\ 0 \\ 1 \\ 4 \\ -2 \end{bmatrix}$

$$w^T = [1, 1, -1, 100, 1]$$

Regressão múltipla

- Encontrar valor para cada parâmetro w_i que reduza o erro cometido pela função
 - Erro: diferença entre valor predito e valor verdadeiro para todos os exemplos
 - Idealmente erro = 0
 - Minimizar função de custo $J(w_0, w_1, w_2 \dots w_d)$

$$J(w_0, w_1, w_2 \dots w_d) = \frac{1}{2n} \sum_{i=1}^n (y^i - f(x^i))^2$$

$$J(w) = \frac{1}{2n} \sum_{i=1}^n (y^i - f(x^i))^2$$

onde:

n é o número de objetos no conjunto de dados

d é o número de atributos preditivos

x^i é o vetor de entrada para o i -ésimo exemplo

y^i é o valor de saída para o i -ésimo exemplo

Sumarizando

- Função hipótese: $f(x) = w_0x_0 + w_1x_1 + \dots + w_dx_d$
- Parâmetros: w_0, w_1, \dots, w_d
- Função de custo: $J(w_0, w_1, \dots, w_d) = J(w) = \frac{1}{2n} \sum_{i=1}^n (y^i - f(x^i))^2$
- Objetivo: $\min_w J(w)$

- Ajuste simultâneo

- $aux_0 = w_0 - \alpha \frac{\partial}{\partial w_0} J(w) = w_0 - \alpha \frac{1}{n} \sum_{i=1}^n (y^i - f(x^i)) x_0^i$
- $aux_1 = w_1 - \alpha \frac{\partial}{\partial w_1} J(w) = w_1 - \alpha \frac{1}{n} \sum_{i=1}^n (y^i - f(x^i)) x_1^i$
- ...
- $aux_d = w_d - \alpha \frac{\partial}{\partial w_d} J(w) = w_d - \alpha \frac{1}{n} \sum_{i=1}^n (y^i - f(x^i)) x_d^i$

Importante diferenciar entre:

$$f(x) = x^4 - 4x^2 + 2x + 4 \quad (PS)$$

$$f(x) = x_1^4 - 4x_2^2 + 2x_3 + 4 \quad (PM)$$

$$w_0 = aux_0$$

$$w_1 = aux_1$$

...

$$w_d = aux_d$$

Regressão com regularização

- Algoritmos de regressão podem induzir modelos sobre-ajustados aos dados (overfitting)
 - Processo de indução do modelo leva em conta detalhes (ruídos) da distribuição dos dados (variância)
 - Possíveis causas de overfitting:
 - Grande número de atributos preditivos ou baixo número de exemplos
 - Baixa proporção do número de exemplos em relação ao número de atributos preditivos
 - A distribuição dos dados é muito complexa
 - Overfitting pode ser reduzido restringindo a complexidade dos modelos induzidos
 - Incorporando um termo de regularização para restringir o valor dos parâmetros
 - Aumenta presença de viés (bias) na função de custo

Regularização

- Funções conseguem se ajustar melhor aos dados se puderem ter valores positivos e negativos muito grandes
- Adiciona um termo de penalidade à função de custo
 - Reduz a complexidade dos modelos gerados
 - Encolhe (*shrink*) os valores dos coeficientes
 - Penaliza função de custo quando coeficientes têm valores elevados
 - Quanto mais complexo o modelo, maior a penalidade

$$J(w) = \frac{1}{2n} \sum_{i=1}^n (y^i - f(x^i))^2 + \lambda \text{Penalidade}$$

- Principais técnicas de regularização:
 - Regressão Lasso
 - Regressão de Ridge
 - Redes elásticas

Lasso

- Least Absolute Shrinkage and Selection Operator
- Regularização L1 (função de perda, loss function, L1)
 - Penalidade: soma dos valores absolutos dos coeficientes
 - Método de menor desvio absoluto
 - Encolhe modelo gerado

$$J(w) = \frac{1}{2n} \sum_{i=1}^n (y^i - f(x^i))^2 + \lambda \|w\|_1$$

$$L1 = \lambda \|w\|_1 = \lambda \sum_{j=1}^d |w_j|$$

Ridge

- Regularização L2 (função de perda, loss function, L2)
 - Penalidade mais usada
 - Quanto maior o valor do parâmetro (positivo ou negativo) , mais ele é penalizado
 - Adiciona à função de custo um termo de penalidade (soma dos quadrados dos coeficientes)

$$J(w) = \frac{1}{2n} \sum_{i=1}^n (y_i - f(x^i))^2 + \lambda \|w\|_2^2$$

$$L2 = \lambda \|w\|_2^2 = \lambda \sum_{j=1}^d w_j^2$$

Rede elástica

- Elastic net
- Combina a regressão Lasso com a regressão de Ridge
 - Utilizando as penalidades L1 e L2

- L1 para gerar dados esparsos
- L2 para remover limite de número de variáveis selecionadas

$$J(w) = \frac{1}{2n} \sum_{i=1}^n (y_i - f(x^i))^2 + \lambda_1 \sum_{j=1}^d |w_j| + \lambda_2 \sum_{j=1}^d w_j^2$$

- Alternativa:

$$J(w) = \frac{1}{2n} \sum_{i=1}^n (y_i - f(x^i))^2 + \lambda \sum_{j=1}^d |w_j| + (1 - \lambda) \sum_{j=1}^d w_j^2$$

Conclusão

- Tarefas de regressão
- Regressão linear
 - Simples
 - Múltipla
- Regressão polinomial
 - Simples
 - Múltipla
- Algoritmo de ajuste de parâmetros
- Regularização

Fim do
apresentação