

Análise de Dados com Base em Processamento Massivo em Paralelo

Aula 8: Explorando o Módulo pyspark.sql

Cristina Dutra de Aguiar
ICMC/USP
cdac@icmc.usp.br



Conteúdo das Aulas

	Foco	Detalhamento
Aula 05	Pandas	diversos métodos consultas sobre DataFrames
Aula 06	Apache Spark RDD	diversos métodos manipulação de RDDs
Aula 07	Módulo pyspark.sql	método spark.sql() consultas textuais em SQL
Aula 08	Módulo pyspark.sql	diversos métodos consultas sobre DataFrames

Infraestrutura Computacional

	Processamento	Ambiente
Aula 05 Pandas	centralizado	um computador
Aula 06 Spark RDD	paralelo e distribuído	<i>cluster</i> de computadores ou computação em nuvem
Aula 07 spark.sql()		
Aula 08 pyspark.sql		

Processamento dos Dados

	Persistência em Disco	Computação em RAM
Aula 05 Pandas	sistema de arquivos local	centralizada
Aula 06 Spark RDD	sistema de arquivos distribuído (HDFS)	distribuída
Aula 07 spark.sql()		
Aula 08 pyspark.sql		

Complexidade de Instalação

	Módulos	Outras Configurações
Aula 05 Pandas	Pandas com suporte de Python	-
Aula 06 Spark RDD	Java Spark findspark pyspark	criação e configuração de sessão configuração de variáveis de ambiente
Aula 07 spark.sql()		
Aula 08 pyspark.sql		

Volume de Dados

	Volume	Escalabilidade Atual
Aula 05 Pandas	grandes volumes	até 5GB
Aula 06 Spark RDD	gigantescos volumes	até 1TB
Aula 07 spark.sql()		
Aula 08 pyspark.sql		

Velocidade de Dados

	Latência	Módulo
Aula 05 Pandas	lote	-
Aula 06 Spark RDD	lote e <i>streaming</i>	Apache Spark Streaming
Aula 07 spark.sql()	lote	Apache Spark SQL
Aula 08 pyspark.sql		

Variedade de Dados

	Tipo de Dados	Conceito Subjacente
Aula 05 Pandas	estruturados	DataFrames
Aula 06 Spark RDD	estruturados, semiestruturados e não estruturados	RDDs
Aula 07 spark.sql()	estruturados	DataFrames construídos sobre RDDs
Aula 08 pyspark.sql		

Abstração do Conceito de RDD

	Nível	Detalhamento
Aula 05 Pandas	-	-
Aula 06 Spark RDD	baixo	RDDs manipulados diretamente
Aula 07 spark.sql()	alto	uso de comandos SQL
Aula 08 pyspark.sql	alto	uso de métodos funcionais

Abstração Problema e Solução

	Programação	Detalhamento
Aula 05 Pandas	funcional	como os dados devem ser obtidos
Aula 06 Spark RDD		
Aula 07 spark.sql()	declarativa	quais dados devem ser obtidos
Aula 08 pyspark.sql	funcional	como os dados devem ser obtidos

Grau de Conhecimento do Usuário

	Experiente em
Aula 05 Pandas	resolução de consultas passo a passo
Aula 06 Spark RDD	uso de métodos de baixo nível programação paralela e distribuída
Aula 07 spark.sql()	uso da linguagem SQL
Aula 08 pyspark.sql	resolução de consultas passo a passo programação paralela e distribuída

Agenda

- Métodos de Interesse
- Consultas OLAP
- ~~Comparativo Pandas, Spark RDD e Spark SQL~~